

Trabalho Prático Final: Mineração de Dados Aplicada

Contextualização

Este trabalho tem como objetivo proporcionar aos alunos uma experiência prática completa no desenvolvimento de um **Projeto de Mineração de Dados**, utilizando um framework estruturado como o **KDD** (Knowledge Discovery in Databases), entretanto, outras metodologias, como CRISP-DM podem ser utilizadas.

O foco do trabalho é explorar dados de interesse real, preferencialmente obtidos de bases públicas. Uma boa referência para busca de datasets é a plataforma **Kaggle**, que oferece diversas bases de dados em diferentes domínios. Outras fontes também podem ser utilizadas, como por exemplo UCI Machine Learning Repository.

Objetivos do Trabalho

- Aplicar as etapas de um processo de mineração de dados estruturado (CRISP-DM ou KDD).
- Formular claramente um objetivo de negócio e um objetivo de mineração, alinhando-os aos dados disponíveis.
- Realizar um diagnóstico dos dados, avaliando sua qualidade, características e limitações.
- Escolher e aplicar técnicas de mineração de dados adequadas ao problema.
- Executar as etapas de pré-processamento, preparação dos dados e ajuste de algoritmos.
- Interpretar os resultados, avaliar sua qualidade e refletir criticamente sobre as decisões tomadas no processo.
- Documentar todo o processo, destacando desafios, escolhas, resultados e oportunidades de melhoria.

Etapas do Trabalho

1. Definição do Problema e Compreensão do Negócio
 - Definir claramente o problema que se deseja resolver.

- Estabelecer o objetivo do negócio e o objetivo da mineração.
2. Compreensão dos Dados
 - Escolha do dataset (podendo ser de plataformas como o Kaggle, bases abertas ou outros repositórios relevantes).
 - Análise exploratória dos dados (perfilamento, identificação de inconsistências, distribuição de atributos, etc.).
 3. Preparação dos Dados
 - Limpeza dos dados, tratamento de valores ausentes e ruídos.
 - Seleção de atributos relevantes.
 - Transformações necessárias (normalização, discretização, encoding, etc.).
 4. Modelagem
 - Escolha de técnicas de mineração de dados, preferencialmente algoritmos de classificação (como Árvore de Decisão, Random Forest, Naïve Bayes, Regressão Logística, KNN, SVM, etc.).
 - Aplicação dos algoritmos, incluindo ajustes de parâmetros e experimentações.
 5. Avaliação
 - Análise dos resultados.
 - Validação dos modelos e interpretação dos padrões encontrados.
 6. Apresentação dos Resultados
 - Geração de insights.
 - Discussão dos resultados frente aos objetivos iniciais.

Entregas:

- **Artigo Científico, utilizando template da SBC, no máximo 10 páginas,** uma sugestão de estrutura para o artigo encontra-se ao final deste documento.
- **Apresentação Oral,** de até 15 minutos, abordando os principais pontos do projeto e os resultados obtidos.

Observações sobre a Avaliação

- O foco principal está na correta condução do processo de mineração de dados, não necessariamente na obtenção de modelos perfeitos ou padrões definitivos.
- A avaliação considerará tanto o relatório quanto a apresentação, incluindo a participação individual de cada integrante.
- Diferentes grupos **NÃO** podem utilizar o mesmo dataset.

Composição dos Grupos

- Grupos de 2 integrantes.

Datas Importes

- Definição dos Grupos e Datasets: 24/06 (Via fórum)
- **Apresentações: 01/07**

Sugestão de Estrutura do Artigo

1. Introdução

- Contextualização do problema.
- Motivação para o estudo.
- Objetivo de negócio.
- Objetivo de mineração de dados.
- Organização do artigo.

2. Referencial Teórico e Trabalhos Correlatos

- Conceitos teóricos relacionados ao problema abordado.
- Técnicas de mineração de dados utilizadas.
- Trabalhos relacionados encontrados na literatura.

3. Metodologia

Descrever detalhadamente o processo de mineração de dados realizado, contemplando:

3.1 Compreensão dos Dados

- Descrição do dataset.
- Fonte dos dados.
- Quantidade de registros e atributos.
- Tipos de variáveis.
- Análise exploratória inicial.
- Identificação de problemas nos dados (valores ausentes, inconsistências, desbalanceamento, etc.).

3.2 Preparação dos Dados

- Limpeza dos dados.
- Tratamento de valores faltantes.
- Tratamento de outliers.
- Codificação de atributos categóricos.
- Normalização ou padronização (quando aplicável).

- Seleção ou criação de atributos.
- Divisão entre conjuntos de treinamento e teste.

3.3 Modelagem

- Algoritmos utilizados.
- Justificativa da escolha dos algoritmos.
- Ferramentas e bibliotecas empregadas.
- Configurações e hiperparâmetros testados.
- Estratégia de validação adotada.

4. Resultados e Discussão

- Métricas utilizadas para avaliação.
- Resultados obtidos por cada modelo.
- Comparação entre os algoritmos.
- Análise crítica dos resultados.
- Limitações encontradas durante o processo.

5. Conclusões e Trabalhos Futuros

- Principais conclusões do estudo.
- Atendimento (ou não) dos objetivos propostos.
- Lições aprendidas durante o processo de mineração.
- Possíveis melhorias e trabalhos futuros.